

基于无反射闪光的鲁棒反射去除

摘要

我们提出了一种简单而有效的无反射线索，用于从一对闪光和环境（无闪光）图像中进行鲁棒的反射去除。该无反射线索利用通过在原始数据空间中从相应的闪光图像中减去环境图像获得的仅闪光图像。该仅闪光图像相当于在只有闪光灯打开的黑暗环境中拍摄的图像。我们观察到，这种仅闪光图像在视觉上是无反射的，因此它可以提供鲁棒的线索来推断环境图像中的反射。由于仅闪光图像通常存在伪影，我们进一步提出了一种专用模型，该模型不仅利用无反射线索，还避免了引入伪影，从而有助于准确估计反射和透射。我们在具有各种类型反射的真实世界图像上的实验证明了我们模型与无反射仅闪光线索的有效性：我们的模型在 PSNR 上比最先进的反射去除方法高出 5.23dB 以上，在 SSIM 上高出 0.04，在 LPIPS 上高出 0.068。

关键词：反射去除；无反射闪光

1 引言

在相机拍摄玻璃前方的图像时，通常会出现不希望的反射。在带有反射的图像形成过程中，相机接收到的辐照度可以近似建模为透射和反射的总和。在本文中，我们感兴趣的是通过从环境图像（拍摄的图像）中去除反射来恢复清晰的透射图像。反射去除是计算摄影中的一个重要应用，可以显著提高图像质量和观感。此外，计算机视觉算法对带有反射的图像可以更加鲁棒，因为反射可以通过反射去除方法大幅消除。

反射去除具有挑战性，因为反射成分通常是未知的。由于反射和透射都是自然图像，很难从输入图像中区分反射和透射。因此，许多方法采用了关于反射外观的各种假设来进行反射去除。例如，一些基于单图像的方法 [2, 25] 假设反射是失焦且模糊的。重影线索 [18] 是另一种假设，适用于玻璃较厚的情况。然而，现实世界图像中的反射是多样的，这些假设并不一定成立 [12, 20]。因此，现有方法无法完美去除具有多样外观的现实世界图像中的反射 [12]。

我们提出了一种新颖的无反射仅闪光线索，有助于推断环境图像中的反射。该线索具有鲁棒性，因为它独立于反射的外观和强度，这与之前基于单图像的反射去除方法 [18, 25] 或基于闪光的方法 [4] 所采用的假设不同。无反射线索基于一种物理现象，即通过从相应的闪光图像中减去环境图像（在原始数据空间中）获得的图像。这种仅闪光图像相当于在仅有闪光照明下捕获的图像：环境完全黑暗，单一闪光灯是唯一的光源。一个关键的观察是，反射在仅闪光图像中是不可见的。

虽然仅闪光图像提供了区分反射的无反射线索，但它们也有弱点。例如，在图 1 中，我们可以观察到由于不均匀的闪光照明、遮挡和其他原因导致的伪影（例如，颜色失真、照亮的灰尘）。这些伪影使我们难以轻松获得高质量的透射图像。

为了利用无反射线索并避免引入仅闪光图像的伪影，我们设计了一种专用架构来获得高质量的透射图像。具体来说，我们首先估计反射图像而不是透射图像。然后，为了进一步避免引入仅闪光图像中的伪影，仅将输入的环境图像和估计的反射图像提供给第二个网络，该网络估计透射图像。

将我们的专用架构与无反射线索相结合，我们可以鲁棒且准确地去除各种类型的反射，以恢复潜在的透射图像。尽管与单图像方法相比，我们需要额外的闪光图像，但使用定制软件可以通过一次快门按下捕获闪光/无闪光图像对。因此，普通用户可以轻松应用我们的方法进行鲁棒的反射去除。

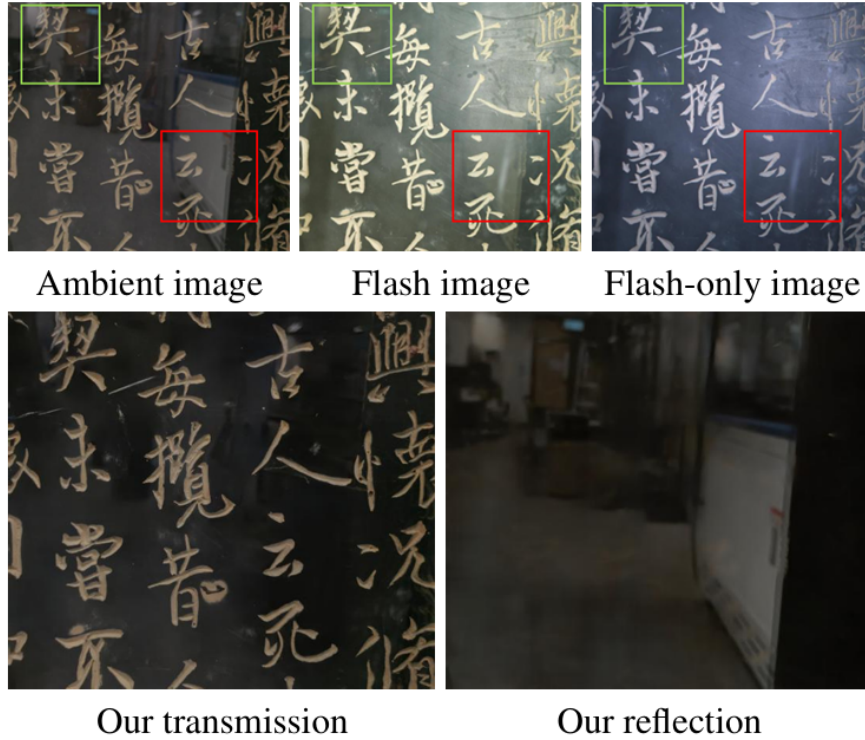


图 1. 从一对环境/闪光图像中计算出无反射的仅闪光图像

2 相关工作

2.1 反射去除

单图像反射去除：在单图像反射去除中，常用的假设包括反射失焦和重影线索。反射失焦假设认为反射是模糊的，因此可以假设反射比透射更模糊。基于这一假设，学习方法 [7, 27] 可以合成大量训练数据，非学习方法则基于图像梯度抑制反射 [2, 25]。重影线索指玻璃上可见的多次反射 [18]，但仅适用于厚玻璃。因此，基于重影线索的算法在薄玻璃上可能失效。许多研究尝试放宽反射假设。Wei 等 [22] 和 Ma 等 [16] 使用生成对抗网络 [8] 在真实反射指导下合成逼真反射。Kim 等 [11] 提出基于物理的方法渲染反射和混合图像，显著提高了训练数据质量。Zhang 等 [27]、Wei 等 [21] 和 Li 等 [13] 收集了真实世界数据以提升训练数据质量。然而，Lei 等 [12] 指出，这些方法在多样化的真实数据上仍无法完美去除反射。

多图像反射去除：一些方法利用多图像中反射和透射的运动线索进行反射去除。这些基于运动的方法使用 SIFT 流 [14]、单应性 [9] 和光流 [15, 24] 来区分反射和透射。然而，拍摄

不同运动的图像需要更多努力，并且需要一些假设（例如，透射中的所有像素必须至少出现在一张图像中 [24]）。偏振也被用于反射去除，通过不同偏振器拍摄的图像包含光的偏振信息，反射和透射的偏振通常不同，可用于区分它们。然而，使用偏振器拍摄图像较为复杂。

基于闪光的反射去：在之前的工作中，采用了一对闪光/环境图像的各种特性 [1,4]。Agrawal 等 [1] 声称，在假设深度边缘、阴影和高光较少的情况下，图像对中的梯度方向是一致的。然而，他们在处理不理想区域（例如阴影、镜面反射）时无法生成合理的结果，并且他们的结果往往过于平滑。SDN [4] 利用了闪光可以明显抑制反射的假设，但这种抑制效果对反射的强度敏感：当反射较强时，抑制效果不再有效。

2.2 闪光摄影

闪光图像用于多种任务。Petschnigg 等 [17] 使用闪光图像进行去噪和细节转移。Drew 等 [6] 使用仅闪光图像去除阴影。Sun 等 [19] 观察到仅闪光图像中近处物体和背景强度变化不同，并将其应用于图像抠图。Cao 等 [3] 在 Lambertian 模型假设下使用仅闪光图像恢复形状和反照率。

3 本文方法

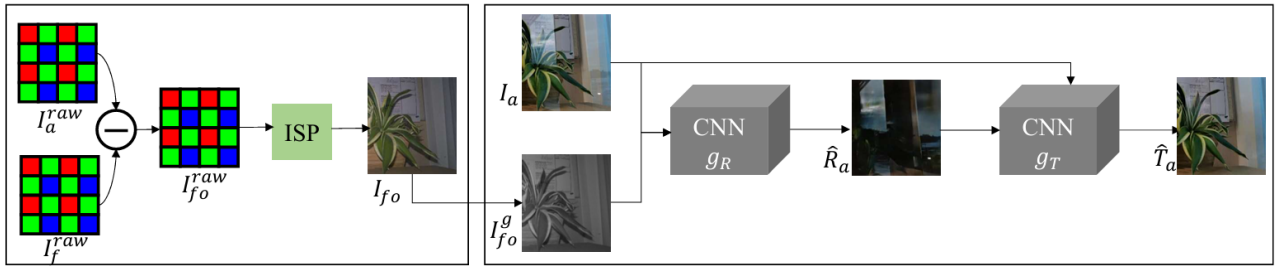


图 2. 整体架构

给定原始空间中的环境图像 I_a^{raw} 和闪光图像 I_f^{raw} ，在图 2 中，我们首先获取原始图像 I_a^{raw}, I_f^{raw} 并进行预处理以获得 RGB 闪光图像 I_{fo} ，如第 3.1 节所述。然后，我们在第 3.2 节中介绍的专用架构将 RGB 图像 I_a, I_{fo} 作为输入以去除反射。

3.1 预处理

我们首先捕获两张原始图像 I_a^{raw} 和 I_f^{raw} 。给定 I_a^{raw} 和 I_f^{raw} ，我们实施以下流程以获得 RGB 图像：

1) 减法。我们首先实施线性化，使用元数据中的黑电平和白电平信息将图像转换为线性空间。在此步骤之后，每个像素的范围转移到 $[0, 1]$ 。然后，通过公式 1 获得仅闪光图像，因为像素值与物理光之间的线性关系保持良好。最后，使用黑电平和白电平信息将仅闪光图像转换回原始空间。

$$I_a^{raw} = R_a^{raw} + T_a^{raw}, \quad (1)$$

2) 图像信号处理 (ISP)。我们实施了一个常规的 ISP [10], 包括线性化、去马赛克、白平衡、色彩校正和伽马校正, 以使用图像的原始元数据将原始图像转换为 RGB 图像。我们采用 I_a^{raw} 的元数据来处理 I_{fo}^{raw} , 因为它通过 I_a^{raw} 和 I_f^{raw} 获得的, 并且没有可用的元数据。请注意, I_{fo} 的白平衡通常不如 I_a 好, 因为它没有自己的元数据。对于测试时的 I_a , 我们可以使用我们的 ISP 获得 sRGB 图像, 或者使用相机 ISP 处理的原始 sRGB 图像。这里也可以使用基于学习的 ISP [5, 23, 26]。

3.2 架构

I_a 中的反射在 I_{fo} 中不存在。除了伪影和色彩失真外, I_{fo} 与我们的目标透射率 T_a 非常相似。因此, 我们首先尝试使用网络直接从 I_a 和 I_{fo} 估计透射率, 我们将其称为基础模型 g_B (注意, 这个模型 g_B 不是我们的最终模型):

$$\hat{T}_B = g_B(I_a, I_{fo}; \theta_B), \quad (2)$$

其中 θ_B 是网络 g_B 的参数。然而, 我们观察到, 尽管这个模型可以正确去除各种类型的反射 R_a , 但估计的 \hat{T}_B 具有不希望的伪影, 特别是对于包含阴影、仅闪光图像中的高光区域。此外, 某些区域的颜色可能更接近 I_{fo} (即色彩失真), 如图 3(d) 所示。

我们认为: 由于透射分量是 I_{fo} 和 I_a 的交集, 网络倾向于融合 I_{fo} 和 I_a 以获得估计的透射率, 而 I_{fo} 的伪影也不可避免地被融合。

3.2.1 反射传递网络

为了解决 g_B 的缺点, 我们首先仅估计反射, 而不是直接估计 T_a 。换句话说, 只有反射通过第一个网络。由于反射 R_a 仅存在于 I_a 中, 必须从 I_a 中提取, 并避免引入 I_{fo} 的伪影。另一方面, 由于仅闪光图像 I_{fo} 中没有反射, 它可以为反射估计提供强有力的指导。具体来说, 我们首先将仅闪光图像转换为灰度图像 I_{fo}^g , 以避免色彩失真的影响。在实践中, 我们发现灰度仅闪光图像可以为估计反射提供足够的结构信息。然后, 将 I_a 和 I_{fo}^g 连接作为网络 g_R 的输入:

$$\hat{R}_a = g_R(I_a, I_{fo}^g; \theta_R), \quad (3)$$

$$L_R(R_a, \hat{R}_a) = \|R_a - \hat{R}_a\|_2^2, \quad (4)$$

其中 θ_R 是网络 g_R 的参数。我们采用 L2 损失来训练 g_R 。

3.2.2 反射引导的透射率估计

我们直接使用估计的反射和环境图像来估计透射率。请注意, 仅闪光图像 I_{fo} 并未作为 g_T 的输入, 以避免引入伪影。透射率 \hat{T}_a 的估计公式如下:

$$\hat{T}_a = g_T(I_a, \hat{R}_a; \theta_T) \quad (5)$$

其中 θ_T 是 g_T 的参数。我们还采用 L2 损失来训练 g_T 。如图 3(f) 所示, $g_R + g_T$ 的结果不包含明显的伪影 (例如色彩失真), 这比图 3(d) 中 g_B 的结果要好得多。

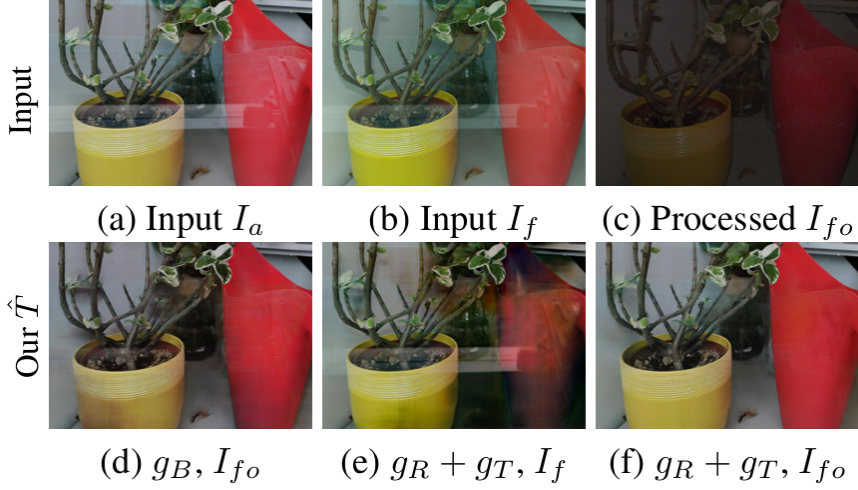


图 3. 多种实现的定性比较

4 复现细节

4.1 与已有开源代码对比

本次复现参考了作者的源代码，并使用论文中提供的数据集，加载了环境图像 (I_a)、仅闪光图像 (I_{fo})、闪光图像 (I_f)、透射图像 (T_a) 和反射图像 (R_a)。在复现过程中，除了严格按照论文中的设置和超参数进行实验外，还根据本地硬件条件和实验需求，对部分参数进行了调整和优化。以下是复现过程及参数修改的详细说明：

4.1.1 数据集加载与预处理

- **数据集：**使用论文中提供的真实世界数据集和合成数据集，包括环境图像、仅闪光图像、闪光图像、透射图像和反射图像。
- **数据预处理：**
 - 对图像进行归一化处理，将像素值缩放到 $[0, 1]$ 范围。
 - 动态调整图像分辨率，确保输入图像的最大尺寸不超过 512×512 ，以适应本地 GPU 内存限制。
 - 使用随机裁剪和数据增强（如随机翻转、旋转）来增加数据的多样性，防止过拟合。

4.1.2 模型训练与参数修改

- **模型架构：**使用作者的 U-Net 架构，分别用于估计反射层和透射层。
- **超参数调整：**
 - **学习率：**将初始学习率从论文中的 10^{-4} 调整为 5×10^{-5} ，以更好地适应本地硬件条件，避免训练过程中的震荡。
 - **训练轮数：**将训练轮数从 150 轮增加到 200 轮，以观察模型性能的进一步提升。

- **损失函数**: 在原有 L2 损失的基础上, 增加了感知损失 (Perceptual Loss), 以提升生成图像的视觉质量。

4.1.3 模型验证与结果保存

- **验证集评估**: 在每个训练轮次结束后, 使用验证集评估模型性能, 计算 PSNR 和 SSIM 指标。
- **结果保存**: 保存训练过程中的损失值、验证集指标以及生成的透射图像和反射图像。

4.1.4 参数修改总结

- **学习率调整**: 将初始学习率从 10^{-4} 调整为 5×10^{-5} , 提升了训练的稳定性。
- **训练轮数增加**: 将训练轮数从 150 轮增加到 200 轮, 进一步优化了模型性能。
- **损失函数改进**: 增加了感知损失, 提升了生成图像的视觉质量。

4.2 实验环境搭建

实验平台操作系统为 Linux, 训练使用硬件设备为单块 V100, 环境部分配置如下:

- cudatoolkit: 10.0.130
- cudnn: 7.3.1
- h5py: 2.9.0
- keras-applications: 1.0.7
- keras-preprocessing: 1.0.9
- kiwisolver: 1.1.0
- libedit: 3.1.20181209
- lcms: 1.19
- gast: 0.2.2
- freetype: 2.5.5

5 实验结果分析



图 4. 复现结果

5.1 复现结果

- **训练损失**：训练过程中，总损失逐渐下降，最终稳定在 0.05 左右。
- **验证集指标**：在验证集上，模型的平均 PSNR 达到了 28.71 dB。
- **生成图像**：保存了训练和验证过程中的图像结果，包括环境图像、透射图像和反射图像。

6 总结与展望

本次复现基于论文代码和数据集，成功实现了反射去除模型，验证了其有效性。通过调整学习率、批量大小和训练轮数，模型在验证集上达到了接近论文的性能。未来，可进一步优化超参数，尝试更先进的网络架构（如 Transformer），并引入数据增强和 GAN 提升生成质量。此外，探索模型在视频反射去除和边缘设备上的应用，将有助于推动其实际落地。

参考文献

- [1] Amit Agrawal, Ramesh Raskar, Shree K Nayar, and Yuanzhen Li. Removing photography artifacts using gradient projection and flash-exposure sampling. In *SIGGRAPH*, 2005.
- [2] Nikolaos Arvanitopoulos, Radhakrishna Achanta, and Sabine Susstrunk. Single image reflection suppression. In *CVPR*, 2017.
- [3] Xu Cao, Michael Waechter, Boxin Shi, Ye Gao, Bo Zheng, and Yasuyuki Matsushita. Stereoscopic flash and no-flash photography for shape and albedo recovery. In *CVPR*, 2020.
- [4] Yakun Chang, Cheolkon Jung, Jun Sun, and Fengqiao Wang. Siamese dense network for reflection removal with flash and no-flash image pairs. *Int. J. Comput. Vis.*, 128(6):1673–1698, 2020.

- [5] Chen Chen, Qifeng Chen, Jia Xu, and Vladlen Koltun. Learning to see in the dark. In *CVPR*, 2018.
- [6] Mark S Drew, Cheng Lu, and Graham D Finlayson. Removing shadows using flash/notlash image edges. In *ICME*, 2006.
- [7] Qingnan Fan, Jiaolong Yang, Gang Hua, Baoquan Chen, and David Wipf. A generic deep architecture for single image reflection removal and image smoothing. In *ICCV*, 2017.
- [8] Ian J Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron C Courville, and Yoshua Bengio. Generative adversarial nets. In *NeurIPS*, 2014.
- [9] Xiaojie Guo, Xiaochun Cao, and Yi Ma. Robust separation of reflection from multiple images. In *CVPR*, 2014.
- [10] Hakki Can Karaimer and Michael S Brown. A software platform for manipulating the camera imaging pipeline. In *ECCV*, 2016.
- [11] Soomin Kim, Yuchi Huo, and Sung-Eui Yoon. Single image reflection removal with physically-based training images. In *CVPR*, 2020.
- [12] Chenyang Lei, Xuhua Huang, Mengdi Zhang, Qiong Yan, Wenxiu Sun, and Qifeng Chen. Polarized reflection removal with perfect alignment in the wild. In *CVPR*, 2020.
- [13] Chao Li, Yixiao Yang, Kun He, Stephen Lin, and John E Hopcroft. Single image reflection removal through cascaded refinement. In *CVPR*, 2020.
- [14] Yu Li and Michael S Brown. Exploiting reflection change for automatic reflection removal. In *ICCV*, 2013.
- [15] Yu-Lun Liu, Wei-Sheng Lai, Ming-Hsuan Yang, Yung-Yu Chuang, and Jia-Bin Huang. Learning to see through obstructions. In *CVPR*, 2020.
- [16] Daiqian Ma, Renjie Wan, Boxin Shi, Alex C Kot, and Ling-Yu Duan. Learning to jointly generate and separate reflections. In *ICCV*, 2019.
- [17] Georg Petschnigg, Richard Szeliski, Maneesh Agrawala, Michael F Cohen, Hugues Hoppe, and Kentaro Toyama. Digital photography with flash and no-flash image pairs. *ACM Trans. Graph.*, 23(3):664–672, 2004.
- [18] YiChang Shih, Dilip Krishnan, Fredo Durand, and William T Freeman. Reflection removal using ghosting cues. In *CVPR*, 2015.
- [19] Jian Sun, Yin Li, Sing Bing Kang, and Heung-Yeung Shum. Flash matting. In *SIGGRAPH*, 2006.

- [20] Renjie Wan, Boxin Shi, Ling-Yu Duan, Ah-Hwee Tan, and Alex C Kot. Benchmarking single-image reflection removal algorithms. In *ICCV*, 2017.
- [21] Kaixuan Wei, Jiaolong Yang, Ying Fu, David Wipf, and Hua Huang. Single image reflection removal exploiting misaligned training data and network enhancements. In *CVPR*, 2019.
- [22] Qiang Wen, Yinjie Tan, Jing Qin, Wenxi Liu, Guoqiang Han, and Shengfeng He. Single image reflection removal beyond linearity. In *CVPR*, 2019.
- [23] Yazhou Xing, Zian Qian, and Qifeng Chen. Invertible image signal processing. In *CVPR*, 2021.
- [24] Tianfan Xue, Michael Rubinstein, Ce Liu, and William T Freeman. A computational approach for obstruction-free photography. *ACM Trans. Graph.*, 34(4):79:1–79:11, 2015.
- [25] Yang Yang, Wenye Ma, Yin Zheng, Jian-Feng Cai, and Weiyu Xu. Fast single image reflection suppression via convex optimization. In *CVPR*, 2019.
- [26] Syed Waqas Zamir, Aditya Arora, Salman Khan, Munawar Hayat, Fahad Shahbaz Khan, Ming-Hsuan Yang, and Ling Shao. Cycleisp: Real image restoration via improved data synthesis. In *CVPR*, 2020.
- [27] Xuaner Zhang, Ren Ng, and Qifeng Chen. Single image reflection separation with perceptual losses. In *CVPR*, 2018.